

Université des Sciences et de la Technologie Houari Boumediene
(USTHB)

Rapport de Projet - Analyse de Données

**Détection d'Usurpation d'Identité
Faciale
(Anti-Spoofing)**

Modélisation, Réduction de Dimension et Classification par Analyse en
Composantes Principales (ACP)

Réalisé par :

Kedjour Chakib Abderrahmane & Ferhat Abderrahmane

Master1 IV 2025/2026 - Module : Analyse de Données

Résumé

Ce projet applique l'Analyse en Composantes Principales (ACP) à un problème de vision par ordinateur : la détection de faux visages, aussi appelée **face anti-spoofing**. Le travail est réalisé à partir du **CASIA Face Anti-Spoofing Dataset**, une base de données utilisée pour étudier les attaques de présentation faciale avec des exemples Real et Fake. À partir d'un ensemble de **1655 images**, chaque visage est transformé en un vecteur de **4096 variables** correspondant aux pixels d'une image **64 × 64**. La matrice de données **X** est ensuite centrée et réduite afin de réaliser une **ACP normée** conforme au cours.

Le rapport présente une étude ACP complète : graphes des individus, valeurs propres, inertie, $\cos^2$, contributions, individus mal représentés, analyse des variables, matrice de corrélation, heatmap, cercles de corrélation, boxplots, biplot, classification, calibration et tests interactifs.

Une première partie utilise les **10 premières composantes** pour faciliter l'interprétation comme dans les TP. Ensuite, une partie d'optimisation teste plusieurs nombres de composantes afin de choisir le meilleur sous-espace pour la classification supervisée par **SVM**. Enfin, les tests par upload et caméra Colab sont présentés avec captures d'écran et interprétation.

Sommaire

- 1 Introduction et contexte du problème
- 2 Modélisation et prétraitement des données
- 3 Application de l'ACP normée
- 4 ACP descriptive avec 10 composantes : tableaux, graphes et interprétation
- 5 Optimisation du nombre de composantes pour la classification
- 6 Classification supervisée, calibration et erreurs
- 7 Tests interactifs : upload, caméra et captures d'écran
- 8 Annexe : tableaux détaillés du notebook
- 9 Limites de l'approche
- 10 Conclusion

1 Introduction et contexte du problème

Les systèmes de reconnaissance faciale sont utilisés dans plusieurs applications de sécurité. Cependant, ils peuvent être trompés par une photo imprimée, une image affichée sur un écran ou une vidéo rejouée. Ce type d'attaque est appelé spoofing facial ou attaque de présentation.

L'objectif du projet est de construire un système capable de classifier automatiquement une image de visage en deux classes : Real lorsque l'image correspond à une personne vivante, et Fake lorsqu'il s'agit d'une attaque. Le cœur de l'étude est l'ACP, utilisée pour réduire la dimension des images et interpréter la structure du nuage d'individus avant la classification.

2 Modélisation et prétraitement des données

2.1 Construction de la matrice X

Le dataset utilisé est CASIA Face Anti-Spoofing Dataset. Chaque image est transformée en un vecteur numérique. Dans la matrice X, chaque ligne représente une image et chaque colonne représente un pixel.

Élément	Valeur utilisée
Dataset	CASIA Face Anti-Spoofing Dataset
Nombre d'images	1 655
Taille après redimensionnement	64 × 64 pixels
Nombre de variables	4 096 pixels
Classes	Real / Fake
Matrice de données	X de taille 1 655 × 4 096




Figure 1 : Exemples d'images du dataset.

Interprétation : Les images sont d'abord différentes visuellement. Le prétraitement les rend comparables : même taille, même format et même représentation numérique.

2.2 Prétraitement

- Passage en niveaux de gris : on garde principalement les contrastes et les textures.
- Redimensionnement en 64 × 64 : toutes les images ont la même taille.
- Vectorisation : chaque image devient un vecteur de 4 096 pixels.
- Centrage-réduction : chaque pixel est transformé par le score réduit $z_{ij} = (x_{ij} - \text{moyenne}_j) / s_j$.

3 Application de l'ACP normée

Comme les variables sont des pixels ayant des intensités différentes, nous utilisons une ACP normée. La matrice centrée-réduite est notée Z. La matrice de corrélation est : $R = (1/m) Z^T Z$.

Les valeurs propres λ_i mesurent l'inertie portée par chaque axe factoriel. Les vecteurs propres associés donnent les directions principales du nuage. Dans le traitement d'images, ces vecteurs propres sont visualisés comme des eigenfaces.

Projection des images : $C = Z U_q$. Chaque image n'est plus représentée par 4 096 pixels, mais par q coordonnées factorielles.

4 ACP descriptive avec 10 composantes : tableaux, graphes et interprétation

Pour l'interprétation comme dans les TP, nous utilisons les 10 premières composantes. Cette partie sert à lire les axes, les individus et les variables ; elle ne remplace pas l'optimisation finale du modèle.

Tableau 1 : Valeurs propres, taux d'inertie et inertie cumulée des 10 premières composantes.

	Axe	Valeur propre	Taux inertie (%)	Inertie cumulée (%)
0	F1	796.053833	19.419243	19.419243
1	F2	464.367554	11.327960	30.747202
2	F3	281.151245	6.858511	37.605713
3	F4	189.804718	4.630169	42.235886
4	F5	142.567978	3.477858	45.713741
5	F6	119.855934	2.923812	48.637550
6	F7	97.452469	2.377293	51.014847
7	F8	84.032318	2.049917	53.064762
8	F9	79.075279	1.928993	54.993755
9	F10	73.045097	1.781890	56.775646
10	F11	61.568169	1.501918	58.277565

Interprétation : Les deux premiers axes expliquent environ 30,75 % de l'information, et les 10 premiers axes environ 56,78 %. Les premières composantes portent donc l'essentiel de l'inertie, ce qui est attendu en ACP.




Figure 2 : Valeurs propres des 10 premières composantes.

Interprétation : La décroissance des valeurs propres montre que F1 est l'axe dominant. Les axes suivants apportent une information complémentaire plus faible.




Figure 3 : Inertie cumulée sur les 10 premières composantes.

Interprétation : Avec 10 composantes, on garde une partie importante de l'information, suffisante pour expliquer les graphes, mais pas forcément optimale pour la classification.




Figure 4 : Graphe des individus train dans le plan F1-F2.

Interprétation : Chaque point représente une image. On observe une tendance de séparation entre Real et Fake, mais il existe une zone de mélange. Les deux premiers axes expliquent une partie de la différence, mais pas toute la séparation.




Figure 5 : Graphe des individus validation dans le plan F1-F2.

Interprétation : Le nuage de validation confirme la zone de mélange. Les images proches de cette zone sont plus difficiles à classer.




Figure 6 : Boxplots des coordonnées factorielles sur les premiers axes.

Figure 6 : Boxplots des coordonnées factorielles sur les premiers axes.

Interprétation : Les boxplots comparent la dispersion des classes sur chaque axe. Quand les boîtes Real et Fake sont décalées, l'axe aide à distinguer les classes ; quand elles se chevauchent, l'axe seul n'est pas suffisant.

4.1 Qualité de représentation et contributions

Tableau 2 : Rappel des notions ACP utilisées.

Notion	Formule utilisée	Lecture simple
Qualité $\cos^2$	$\cos^2 i(q) = \text{somme } c_{ik}^2 / \ z_i\ ^2$	Proche de 1 : individu bien représenté
Contribution	$\text{CTR } j(i) = (1/m) \times c_{ij}^2 / \lambda_j$	Grande valeur : individu important pour l'axe
Individu mal représenté	$\cos^2$ faible	L'information est portée par d'autres axes

Tableau 3 : Exemple de qualité de représentation $\cos^2$ des premiers individus.

	Image	Classe	Qualité axe F1	Qualité axe F2	Qualité axe F3
0	9_8.avi_125_fake.jpg	Fake	0.043070	0.215657	0.056080
1	1_7.avi_175_fake.jpg	Fake	0.016828	0.586308	0.004547
2	4_6.avi_125_fake.jpg	Fake	0.090334	0.252749	0.053911
3	16_8.avi_100_fake.jpg	Fake	0.096271	0.109382	0.020332
4	3_3.avi_50_fake.jpg	Fake	0.234728	0.008414	0.164300
5	4_8.avi_175_fake.jpg	Fake	0.121879	0.198991	0.000014
6	17_HR_3.avi_75_fake.jpg	Fake	0.272384	0.126725	0.013094
7	13_7.avi_75_fake.jpg	Fake	0.011895	0.147901	0.168275
8	4_HR_2.avi_200_fake.jpg	Fake	0.283398	0.264189	0.002083
9	11_HR_3.avi_50_fake.jpg	Fake	0.066834	0.037099	0.075573

Interprétation : Le $\cos^2$ indique si un individu est bien décrit par un axe. Les valeurs élevées montrent que l'axe explique bien la position de l'image ; les valeurs faibles indiquent que l'image doit être interprétée avec d'autres axes.

Tableau 4 : Exemple de contributions des premiers individus aux axes F1, F2 et F3.

	Image	Classe	Contribution F1 (%)	Contribution F2 (%)	Contribution F3 (%)
0	9_8.avi_125_fake.jpg	Fake	0.011726	0.100654	0.043231
1	1_7.avi_175_fake.jpg	Fake	0.010262	0.612903	0.007851
2	4_6.avi_125_fake.jpg	Fake	0.029041	0.139294	0.049073
3	16_8.avi_100_fake.jpg	Fake	0.020343	0.039623	0.012165
4	3_3.avi_50_fake.jpg	Fake	0.127463	0.007832	0.252615
5	4_8.avi_175_fake.jpg	Fake	0.037381	0.104624	0.000012
6	17_HR_3.avi_75_fake.jpg	Fake	0.110651	0.088250	0.015061
7	13_7.avi_75_fake.jpg	Fake	0.005217	0.111204	0.208972
8	4_HR_2.avi_200_fake.jpg	Fake	0.128344	0.205105	0.002670
9	11_HR_3.avi_50_fake.jpg	Fake	0.020666	0.019665	0.066166

Interprétation : La contribution indique quelles images construisent les axes. Une forte contribution signifie que l'image influence beaucoup la direction factorielle.

Tableau 5 : Individus les moins bien représentés sur le plan F1-F2.

	Image	Classe	Qualité axe F1	Qualité axe F2	Qualité axe F3	Qualité plan F1-F2	Signe F1	Signe F2
1186	7_HR_2.avi_150_fake.jpg	Fake	0.000204	0.000289	0.120389	0.000493	-	-
912	18_5.avi_50_fake.jpg	Fake	0.001867	0.000444	0.079024	0.002311	+	-
12	7_HR_2.avi_125_fake.jpg	Fake	0.001417	0.004315	0.106657	0.005732	+	+
463	12_8.avi_175_fake.jpg	Fake	0.009651	0.000077	0.023518	0.009729	-	+
784	11_5.avi_25_fake.jpg	Fake	0.010245	0.000463	0.024841	0.010708	+	-
757	18_5.avi_75_fake.jpg	Fake	0.010975	0.000004	0.107784	0.010979	+	-
858	5_HR_1.avi_125_real.jpg	Real	0.000192	0.012218	0.245695	0.012409	-	+
839	18_6.avi_25_fake.jpg	Fake	0.001907	0.017141	0.030042	0.019048	+	-
672	12_8.avi_150_fake.jpg	Fake	0.020275	0.001665	0.047687	0.021940	-	+
823	20_8.avi_50_fake.jpg	Fake	0.022039	0.000706	0.208845	0.022746	-	+

Interprétation : Ces individus ont une faible qualité sur F1-F2. Ils ne doivent pas être interprétés uniquement à partir du premier plan factoriel, car leur information est surtout portée par d'autres composantes.

4.2 Analyse des variables : pixels, corrélations et cercles

Tableau 6 : Coordonnées des premières variables/pixels sur F1, F2 et F3.

	Variable	Coord F1	Coord F2	Coord F3
0	px(0,0)	0.836790	-0.122029	-0.008041
1	px(0,1)	0.850174	-0.110731	0.023903
2	px(0,2)	0.857900	-0.106241	0.029777
3	px(0,3)	0.857845	-0.118997	0.037776
4	px(0,4)	0.855185	-0.123546	0.036612
5	px(0,5)	0.845214	-0.110432	0.035735
6	px(0,6)	0.845638	-0.103179	0.035249
7	px(0,7)	0.833734	-0.086407	0.039556
8	px(0,8)	0.824019	-0.085311	0.039850
9	px(0,9)	0.709698	-0.089791	0.020543

Interprétation : Les variables sont ici les pixels. Les coordonnées indiquent comment chaque pixel est lié aux axes factoriels.

Tableau 7 : Pixels les plus contributeurs aux axes principaux.

	Variable	Contribution F1 (%)	Contribution F2 (%)	Contribution F3 (%)
2670	px(41,46)	0.000014	0.130598	0.002419
2669	px(41,45)	0.000088	0.130124	0.003166
2606	px(40,46)	0.000036	0.129122	0.004915
2733	px(42,45)	0.000658	0.126090	0.000101
2671	px(41,47)	0.000004	0.126716	0.001877
2605	px(40,45)	0.000037	0.126329	0.006968
2734	px(42,46)	0.000304	0.124559	0.000215
2607	px(40,47)	0.000007	0.124421	0.004113
2775	px(43,23)	0.001539	0.122239	0.000007
2711	px(42,23)	0.000895	0.122083	0.000477

Interprétation : Les pixels les plus contributeurs correspondent à des zones importantes du visage ou de l'arrière-plan. Ils aident à comprendre quelles parties de l'image influencent la séparation Real/Fake.




Figure 7 : Heatmap de corrélation des pixels les plus contributifs.

Interprétation : Les pixels proches ou appartenant à une même zone du visage sont souvent fortement corrélés. Cela signifie qu'ils varient ensemble et peuvent participer au même axe factoriel.




Figure 8 : Cercle de corrélation F1-F2 des variables importantes.

Interprétation : Les flèches proches indiquent des variables corrélées positivement. Les variables proches du cercle sont mieux représentées dans le plan F1-F2.




Figure 9 : Cercle de corrélation F1-F3.

Interprétation : Le plan F1-F3 complète l'analyse de F1-F2. Certaines variables peuvent être mieux expliquées par F3, ce qui justifie l'étude de plusieurs axes.




Figure 10 : Eigenfaces des premières composantes principales.

Interprétation : Les eigenfaces sont les vecteurs propres visualisés comme des images. Elles représentent les grands motifs de variation : illumination, contours, texture et zones du visage.




Figure 11 : Carte des pixels contributeurs à F1.

Interprétation : Cette carte montre les zones qui contribuent le plus au premier axe. Les zones claires représentent les pixels les plus influents.




Figure 12 : Carte des pixels contributeurs à F2.

Interprétation : La carte de F2 est différente de celle de F1. Chaque axe porte donc une information différente sur le visage et sur les conditions Real/Fake.




Figure 13 : Biplot individus et variables importantes.

Interprétation : Le biplot combine les images et les pixels importants. Il permet de relier la position des individus aux variables qui influencent cette position.

5 Optimisation du nombre de composantes pour la classification

Après l'interprétation avec 10 composantes, nous testons plusieurs nombres de composantes pour la classification. Pour chaque valeur q , on applique ACP(q), puis un SVM RBF équilibré, et on compare les scores.

Tableau 8 : Test de plusieurs nombres de composantes et scores de classification.

	Nombre d'axes	Inertie cumulée (%)	Accuracy	Balanced accuracy	F1-score macro	Real prédits Fake	Fake prédits Real
7	150	92.357857	0.978261	0.962152	0.970026	7	2
5	115	90.010506	0.975845	0.960554	0.966811	7	3
6	120	90.415802	0.975845	0.960554	0.966811	7	3
1	40	77.562157	0.973430	0.958957	0.963618	7	4
3	80	86.204079	0.975845	0.957201	0.966578	8	2
4	100	88.622978	0.975845	0.957201	0.966578	8	2
0	20	67.545959	0.973430	0.955604	0.963365	8	3
2	59	82.593040	0.973430	0.955604	0.963365	8	3

Interprétation : Le meilleur résultat de validation est obtenu avec 150 composantes. Ce choix n'est donc pas arbitraire : il vient d'un test expérimental ACP(q) + SVM. Les 10 composantes servent à interpréter les graphes, tandis que 150 composantes servent au modèle final.




Figure 14 : Optimisation - nombre de composantes et performance SVM.

Interprétation : L'inertie augmente avec le nombre de composantes. La balanced accuracy permet de choisir le meilleur compromis entre Real et Fake.

6 Classification supervisée, calibration et erreurs

Tableau 9 : Comparaison des modèles de classification après ACP.

	Modèle	Accuracy validation	Balanced accuracy	F1-score macro	Real prédits Fake	Fake prédits Real
2	SVM RBF équilibré	0.978261	0.962152	0.970026	7	2
0	Logistic Regression équilibrée	0.910628	0.907364	0.885147	10	27
1	SVM Linear équilibré	0.905797	0.900816	0.878939	11	28
4	Random Forest équilibré	0.929952	0.859789	0.894938	28	1
3	KNN	0.913043	0.855313	0.875188	26	10

Interprétation : Le SVM RBF équilibré donne les meilleurs résultats de validation. Il est donc retenu comme modèle final car il sépare mieux les classes dans l'espace ACP.




Figure 15 : Matrice de confusion validation - SVM RBF équilibré.

Interprétation : La majorité des images est bien classée. Les erreurs restantes correspondent aux zones de mélange observées dans le plan factoriel.

Tableau 10 : Comparaison entre décision standard et seuil Real calibré.

	Décision	Balanced accuracy	Recall Real	Recall Fake	Real prédits Fake	Fake prédits Real
0	Standard model.predict()	0.962152	0.930693	0.99361	7	2
1	Seuil Real calibré = 0.20	0.968858	0.950495	0.98722	5	4

Interprétation : La calibration améliore l'équilibre entre Real et Fake. Elle réduit certains Real prédits Fake, mais peut légèrement augmenter Fake prédits Real ; c'est pour cela qu'on l'analyse avec la matrice de confusion.

Tableau 11 : Extrait des seuils testés pour la calibration Real/Fake.

	Seuil Real	Balanced accuracy	Recall Real	Recall Fake	Real prédits Fake	Fake prédits Real	Score choix
0	0.20	0.968858	0.950495	0.987220	5	4	1.111432
1	0.21	0.965505	0.940594	0.990415	6	3	1.106594
2	0.22	0.965505	0.940594	0.990415	6	3	1.106594
3	0.23	0.965505	0.940594	0.990415	6	3	1.106594
4	0.24	0.965505	0.940594	0.990415	6	3	1.106594
5	0.25	0.965505	0.940594	0.990415	6	3	1.106594
6	0.26	0.965505	0.940594	0.990415	6	3	1.106594
7	0.27	0.965505	0.940594	0.990415	6	3	1.106594
8	0.28	0.965505	0.940594	0.990415	6	3	1.106594
9	0.29	0.965505	0.940594	0.990415	6	3	1.106594

Interprétation : Plusieurs seuils sont testés pour éviter de dépendre uniquement du seuil 0,50. Le seuil 0,20 donne un bon compromis dans cette expérimentation.

[Image manquante : cell32_out0.png]

Interprétation : La courbe montre l'évolution du rappel Real, du rappel Fake et de la balanced accuracy selon le seuil. Le choix du seuil se fait donc à partir des résultats et non au hasard.




Figure 17 : Matrice de confusion calibrée sur validation.

Interprétation : Après calibration, le rappel Real augmente, ce qui aide à réduire les vrais visages classés Fake.

Tableau 12 : Erreurs de classification après calibration dans la validation.

	Image	Vraie classe	Classe prédite calibrée	F1	F2	Proba Real
0	5_2.avi_100_real.jpg	Real	Fake	17.641432	-0.339058	0.005128
1	11_HR_1.avi_200_real.jpg	Real	Fake	-25.275749	-18.927671	0.006438
2	20_HR_2.avi_125_fake.jpg	Fake	Real	-49.018471	-21.487625	0.767391
3	7_4.avi_125_fake.jpg	Fake	Real	44.646465	88.254333	0.554345
4	10_1.avi_75_real.jpg	Real	Fake	2.194318	-35.161964	0.035900
5	13_1.avi_150_real.jpg	Real	Fake	24.980833	9.106751	0.024159
6	11_HR_1.avi_325_real.jpg	Real	Fake	-26.999907	-18.095835	0.067634
7	20_HR_2.avi_75_fake.jpg	Fake	Real	-50.948788	-23.709064	0.201446
8	13_6.avi_150_fake.jpg	Fake	Real	9.869653	-12.023803	0.446578

Interprétation : Ces erreurs sont des images situées près de la zone de mélange. Elles expliquent pourquoi la séparation n'est pas parfaite même après ACP et SVM.




Figure 18 : Erreurs de classification après calibration dans le plan ACP.

Interprétation : Les erreurs sont proches des zones où Real et Fake se chevauchent. Cela confirme l'intérêt d'étudier les graphes des individus.




Figure 19 : Matrice de confusion test officiel - décision standard.




Figure 20 : Matrice de confusion test officiel - décision calibrée.

Interprétation : Le test officiel est plus difficile que la validation interne. La version calibrée baisse légèrement l'accuracy globale, mais améliore la balanced accuracy, donc elle équilibre mieux les deux classes.

7 Tests interactifs : upload, caméra et captures d'écran

La dernière partie du notebook est une démonstration pratique. L'utilisateur peut importer une image depuis son ordinateur ou utiliser la caméra Colab. Le pipeline reste identique : prétraitement, centrage-réduction avec le scaler appris, projection ACP, puis décision par SVM.

- Détection ou recadrage du visage dans l'image externe.
- Conversion en niveaux de gris et redimensionnement en 64×64 .
- Vectorisation en 4 096 pixels.
- Centrage-réduction avec le même scaler que le train.
- Projection sur les composantes ACP retenues.
- Décision finale : Real, Fake ou Incertain.

Tableau 13 : Résumé des tests externes upload/caméra.

Image testée	Mode	Prob. Fake	Prob. Real	Distance ACP	Prédiction	Lecture simple
Figure 21	Upload	97.02 %	2.98 %	2913.0	Fake	Image de type attaque : probabilité Fake très élevée.
Figure 22	Upload	95.95 %	4.05 %	4883.9	Fake	Le recadrage visage conserve l'information utile pour la décision.
Figure 23	Caméra Colab	0.89 %	99.11 %	6744.8	Real	La caméra donne une image proche du domaine d'apprentissage.
Figure 24	Upload	0.44 %	99.56 %	6625.7	Real	Image Real externe correctement reconnue.

Interprétation : Les tests externes sont une démonstration. La décision dépend de la probabilité, mais aussi de la distance au nuage ACP. Si l'image est trop éloignée du domaine d'apprentissage, le système peut répondre Incertain.



Figure 21 : Upload d'une image Fake - prédiction Fake.

Interprétation : La probabilité Fake est très élevée. La décision Fake est cohérente avec l'aspect d'attaque de l'image.




Figure 22 : Upload avec visage détecté - prédiction Fake.

Interprétation : Le visage est détecté puis converti en image 64 × 64. Le modèle reste sûr de la classe Fake, ce qui montre que le recadrage garde l'information utile.



Figure 23 : Caméra Colab - prédiction Real.

Interprétation : La caméra Colab fournit une image externe. Après projection ACP, la probabilité Real est très élevée et la distance reste proche du seuil accepté ; la décision Real est donc acceptable.



Figure 24 : Upload d'une image Real - prédiction Real.

Interprétation : Cette capture montre que le pipeline upload fonctionne aussi sur une image réelle. Le modèle utilise le même scaler, la même ACP et le même SVM que pour le dataset.

9 Limites de l'approche

- Changement de domaine : les photos personnelles ou les captures webcam n'ont pas toujours les mêmes conditions que les images du dataset.
- Perte de la couleur : l'ACP est appliquée sur des images en niveaux de gris, ce qui peut supprimer des informations utiles.
- Cadrage du visage : un mauvais alignement peut perturber la projection ACP.
- Une seule image : l'anti-spoofing réel bénéficie souvent de plusieurs trames vidéo, de la profondeur ou du mouvement.
- Caméra Colab : le mode caméra est une capture instantanée ou quasi temps réel, pas une application locale fluide.

10 Conclusion

Ce projet montre que l'ACP peut être appliquée efficacement à la détection de visages falsifiés. L'étude suit la logique du cours : construction de la matrice X , centrage-réduction, matrice de corrélation, valeurs propres, inertie, projection, qualité de représentation, contributions, corrélation, cercles et biplot.

La partie descriptive avec 10 composantes permet d'interpréter les graphes et les axes de manière simple. Ensuite, la partie optimisation montre que le meilleur nombre de composantes pour la classification n'est pas forcément celui choisi uniquement par l'inertie : plusieurs valeurs sont testées et 150 composantes donnent le meilleur résultat de validation.

Enfin, les tests par upload et caméra ajoutent une démonstration pratique. L'évaluation principale reste cependant celle du dataset, car les images externes peuvent être différentes des images d'apprentissage.